Trabajo Práctico Especial

Fundamentos de la Ciencia de Datos

Fecha de entrega: 10/11/2026

Ingeniería de Sistemas

Grupo 19

Integrantes

- Basso Antonella: antobasso111@gmail.com
- Ordorica Abigail:
- Rebainera Facundo: frebainera@alumnos.exa.unicen.edu.ar

Ayudante asignado

- Vitale Santiago

Introducción **3**
1. Análisis inicial de la base, sus datos y atributos. **3**
1.1. Origen y contexto de los datos: 3
1.2. Caracterización de los atributos 3
1.3. Análisis de Distribuciones 4
2- Limpieza de la base **12**
2.1. Limpieza de la variable Cilindrada: 13
2.2. Limpieza de la Economía del Combustible 13
2.3. Limpieza de la Potencia 14
2.4. Limpieza de los Tipos de Combustible 15
2.5- Limpieza de la Relación de Ejes 16
2.6- Limpieza de las emisiones de CO2 17
2.7- Limpieza de la distribución de los Procedimientos de prueba 17
2.8. Limpieza de NULOS 18
2.8.1. Nulos en #of Cylinders and Rotors. 19
2.8.2 Nulos en emisiones de CO2 19
2.8.3 Nulos de RND_ADJ_FE. 21
2.9 Filas Duplicadas 22
3- Planteo de hipótesis **22**
3.1- Hipótesis univariada 22
3.2- Hipótesis bivariada 22
3.3- Hipótesis multivariada 22
4- Validación de las Hipótesis **23**
4.1 Validación de la Hipótesis Univariada 23
4.2 Validación de la Hipótesis Bivariada 24
4.3 Validación de la Hipótesis Multivariada 26
4.4 Hipótesis planteadas por la cátedra 31
Conclusión General **34**

Introducción

En el presente informe se llevará a cabo un análisis detallado del conjunto de datos “EPA Fuel Economy - Model Year 2025”, aplicando las técnicas y metodologías abordadas en la materia Fundamentos de la Ciencia de Datos de la carrera Ingeniería de Sistemas.

Nuestro objetivo principal es explorar la estructura y calidad de los datos, aplicar los procesos de limpieza necesarios e implementar la validación estadística de hipótesis univariadas, bivariadas y multivariadas orientadas a comprender los factores que impactan en la eficiencia del combustible de los vehículos.

---

1. Análisis inicial de la base, sus datos y atributos.

1.1. Origen y contexto de los datos:

En el caso de nuestra base de datos el origen de los mismos proviene del dataset público de certificación y pruebas de emisiones y eficiencia de combustible de la “Agencia de Protección Ambiental de EE.UU“ (EPA) recopilados en conjunto con los fabricantes de automóviles.
El conjunto de registros se obtiene mediante pruebas estandarizadas de laboratorio sobre dinamómetros (bancos de rodillo) que simulan ciclos específicos de manejo como en una ciudad, ruta, a altas velocidades, entre otros.

1.2. Caracterización de los atributos

Al analizar la estructura del dataset es fundamental determinar la unidad de análisis: cada registro o fila no corresponde necesariamente a un modelo de vehículo único, sino a una configuración técnica específica del vehículo sometida a un ensayo oficial.
En consecuencia, un mismo modelo puede aparecer en múltiples registros si presenta variaciones en su motorización, tipo de transmisión, combustible o procedimiento de prueba realizado.
Mediante la inspección técnica con la biblioteca Pandas, la propiedad df.shape devolvió la tupla (4287, 67), confirmando un volumen total de 4.287 ensayos y 67 atributos.
Al examinar sus tipos de datos (df.info() y df.dtypes), las variables se distribuyen en: 29 cuantitativas continuas (métricas decimales de consumo, rendimiento y capacidad física), 9 cuantitativas discretas (conteos enteros de componentes como cilindros y marchas), 29 cualitativas / categóricas (atributos descriptivos e identificadores nominales como marca, tracción, combustible).

Si bien, como mencionamos anteriormente, la base de datos cuenta originalmente con 67 variables decidimos trabajar específicamente con 13 atributos claves para cumplir con el objetivo del trabajo.

A continuación se detallan las variables seleccionadas con sus respectivas especificaciones:

- **RND_ADJ_FE:** cuantitativa continua - representa la economía de combustible ajustada del vehículo, medida en MPG.
- **Test Veh Displacement:** cuantitativa continua - volumen desplazado por el motor en litros.
- **Rated Horsepower:** cuantitativa continua - potencia máxima expresada en caballos de fuerza.
- **# of Cylinders and Rotors:** cuantitativa discreta - número entero de cilindros del motor.
- **Equivalent Test Weight:** cuantitativa continua - masa asignada para las pruebas en dinamómetro.
- **# of Gears:** cuantitativa discreta - número de velocidades de la transmisión.
- **Tested Transmission Type:** cualitativa nominal - clasificación del mecanismo de cambios (manual, automática, CVT, etc).
- **Drive System Description:** cualitativa nominal - eje motriz del vehículo (FWR, RWD, AWD/4WD).
- **Test Fuel Type Description:** cualitativa nominal - fuente de energía empleada (gasolina regular, premium, diesel, electricidad).
- **Vehicle Type:** Cualitativa nominal - clasifica los vehículos entre categorías como Car, Truck o Both.
- **Axle Ratio:** Cuantitativa continua - Es una característica de la transmisión que relaciona las velocidades de rotación del sistema de transmisión final.
- **CO2 (g/mi):** Cuantitativa continua - Indica las emisiones de dióxido de carbono por milla.
- **Test Procedure Description:** Cualitativa nominal - Identifica el procedimiento bajo el cual se realizó el ensayo.

1.3. Análisis de Distribuciones

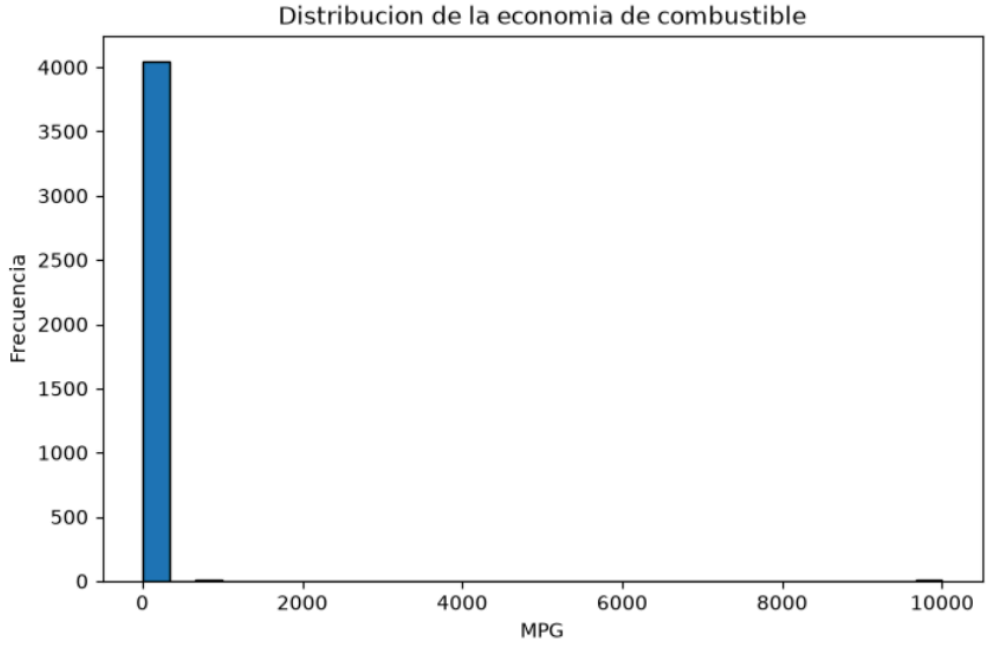
A continuación se presenta el análisis individual de cada variable seleccionada. Para las variables cuantitativas utilizamos histogramas de frecuencia con estimación de densidad de kernel (KDE) y gráficos de caja (*boxplots*) ya que ayudan a identificar asimetrías y valores extremos, mientras que para las variables cualitativas o discretas de baja cardinalidad utilizamos gráficos de barras de frecuencia que nos permiten comparar cuántas observaciones hay en cada categoría.

Inspeccionamos la presencia de valores nulos mediante el cálculo del porcentaje de datos faltantes por variable dentro del dataframe.
Según la documentación de la cátedra, muchas de estas variables son específicas de ciertos cálculos o configuraciones y pueden no estar disponibles para todos los ensayos. Por eso, sus nulos no necesariamente representan errores, por lo cual, para cada variable seleccionada, evaluamos y definimos la estrategia de tratamiento más adecuada.

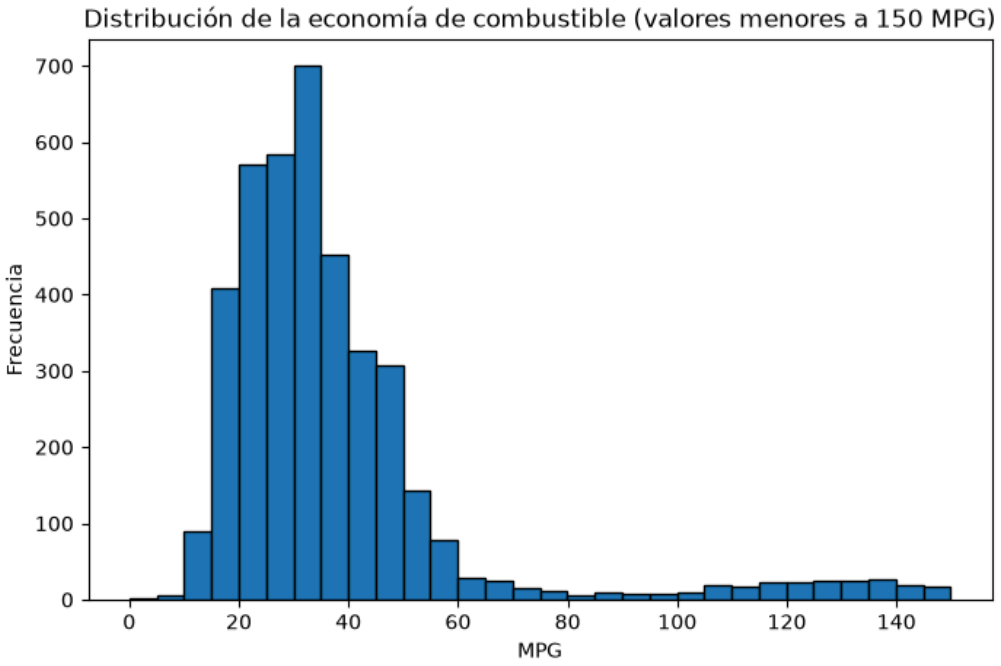
Con respecto a los registros repetidos, si bien no hay filas exactamente iguales la combinación que la propia documentación indica como identificadora de una configuración

(Veh Mfr Code + Test Vehicle ID + Test Veh Configuration) si se repite en diferentes casos. Esto se debe a que un mismo vehículo puede aparecer en varios registros porque fue sometido a distintos ensayos, por ejemplo, pruebas de conducción urbana y de ruta.

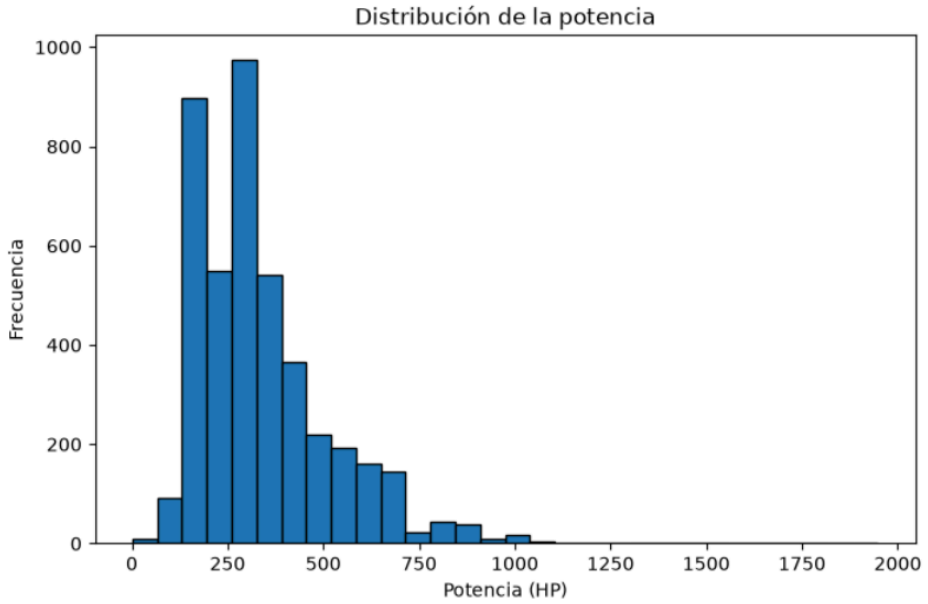
1. RND_ADJ_FE (distribucion de la economia del combustible):



Observaciones: en el gráfico casi todos los valores se concentran cerca del extremo izquierdo, pero aparecen algunos valores extremadamente altos, cercanos a 10.000 MPG. Esto hace que el resto de los datos queden comprimidos y no podamos apreciar bien su distribución por lo que debemos investigar su causa antes de tratarlos. La distribución actual no nos permite interpretar correctamente los valores por lo que decidimos temporalmente ignorar los valores extremos para poder ver mejor la distribución:

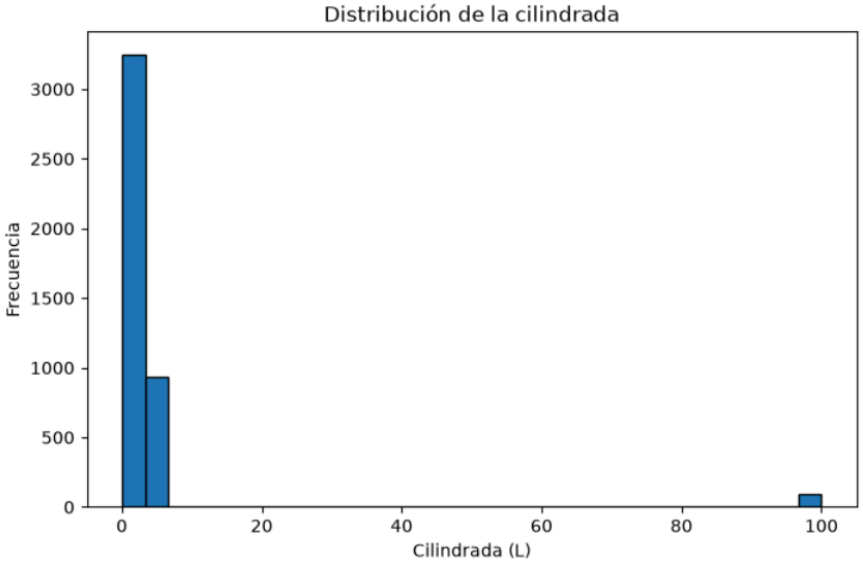


2. Rated Horsepower (potencia):

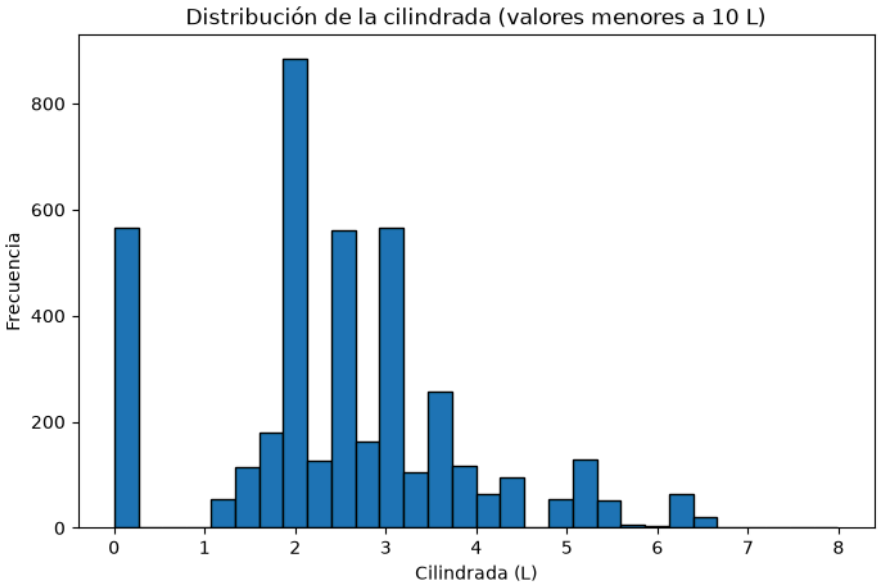


Observaciones: en el extremo izquierdo del eje horizontal se observa una barra de 0HP, lo cual nos resulta particular ya que no existen autos con cero caballos de fuerza, posiblemente se trate de un valor centinela. Luego la mayoría de los vehículos se concentran aproximadamente entre 150 y 500 HP. A medida que aumenta la potencia, disminuye la cantidad de ensayos, aunque aparecen algunos casos con valores superiores a 1.000 HP los cuales vimos que corresponden a autos superdeportivos o eléctricos de alto rendimiento.

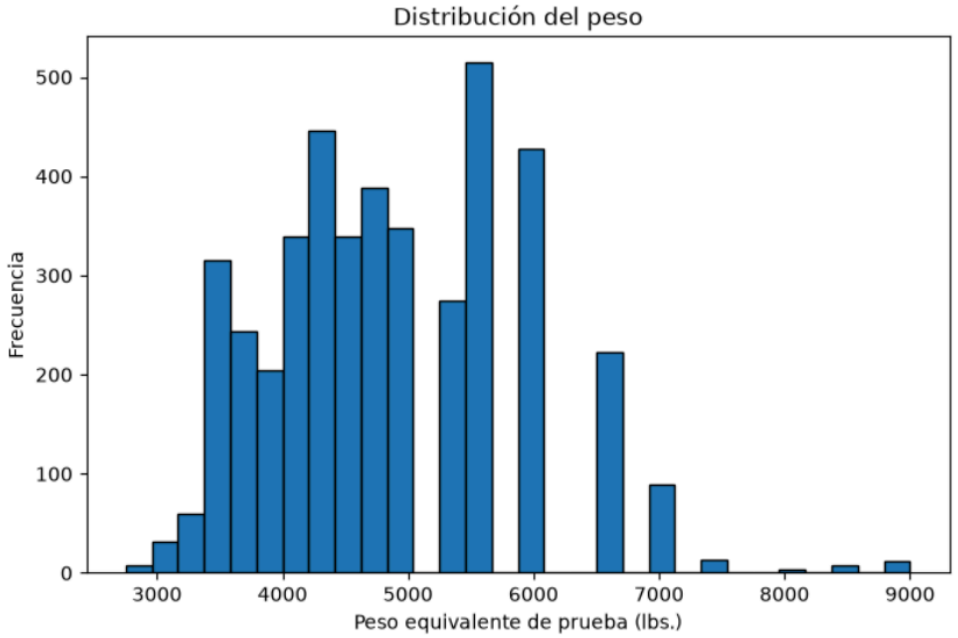
3. Test Veh Displacement (Cilindrada)



Observaciones: la mayoría de los valores se concentran en un rango relativamente bajo, pero aparece un valor cercano a los 100 litros, distante del resto de la distribución. Debemos revisar la fila correspondiente y la documentación antes de decidir qué hacer con él.
Sacamos temporalmente un valor extremo para poder ver mejor la distribución:

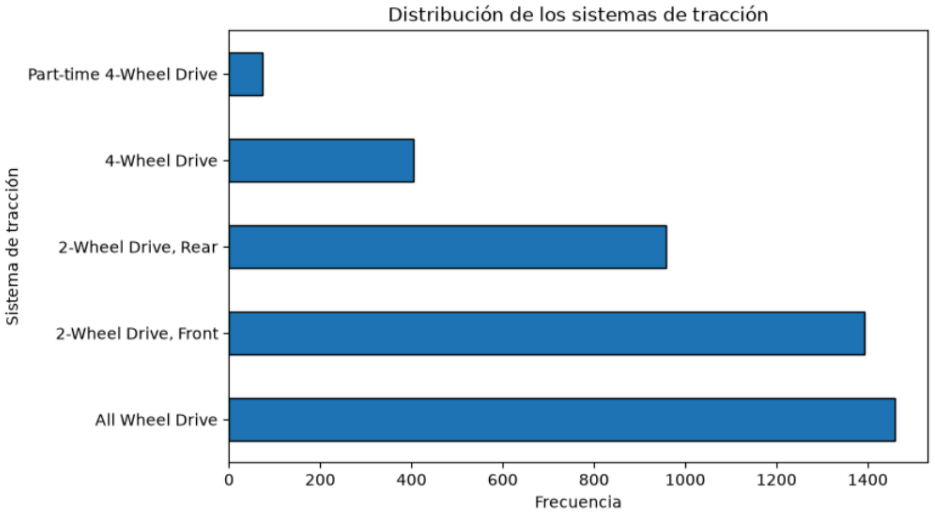


4. Equivalent Test Weight (Peso)



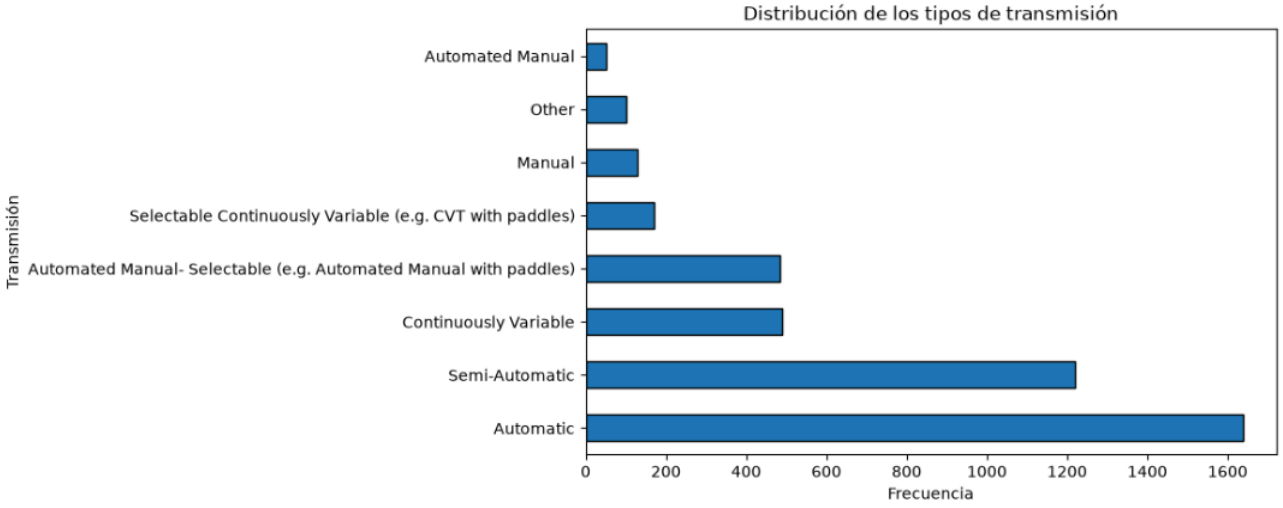
Observaciones: La distribución no es perfectamente simétrica, la mayor parte de los vehículos se concentran aproximadamente entre 3.500 y 6.500 libras. También aparecen algunos vehículos más pesados, con valores que llegan a cerca de 9.000 libras. Teniendo en cuenta que en las simulaciones se agrega peso estandarizado a cargas y pasajeros no consideramos que existan errores en los datos de esta variable.

5. Drive System Description (Sistemas de Tracción)



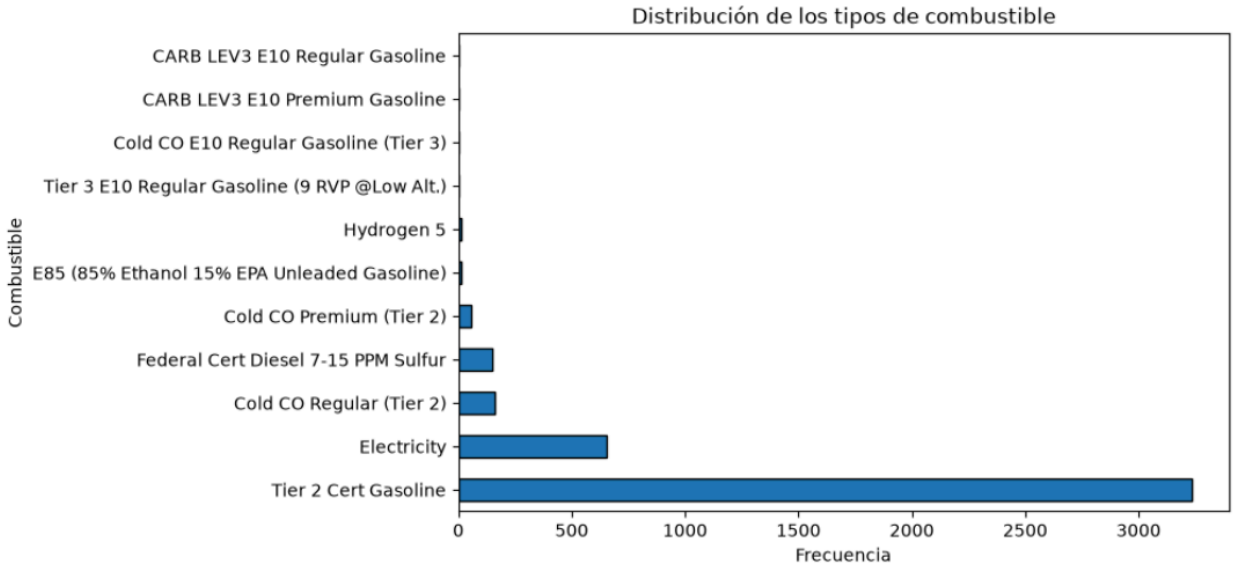
Observaciones: las categorías All Wheel Drive y 2-Wheel Drive, Front Drive concentran las mayores frecuencias. Vemos que hay un alto nivel de fragmentación de las variables al diferenciar técnicamente entre tracción integral permanente, acoplable y temporal. Sugerimos unificar las categorías en tres bloques principales: tracción integral/total, delantera y trasera.

6. Tested Transmission Type (Tipo de Transmisión)



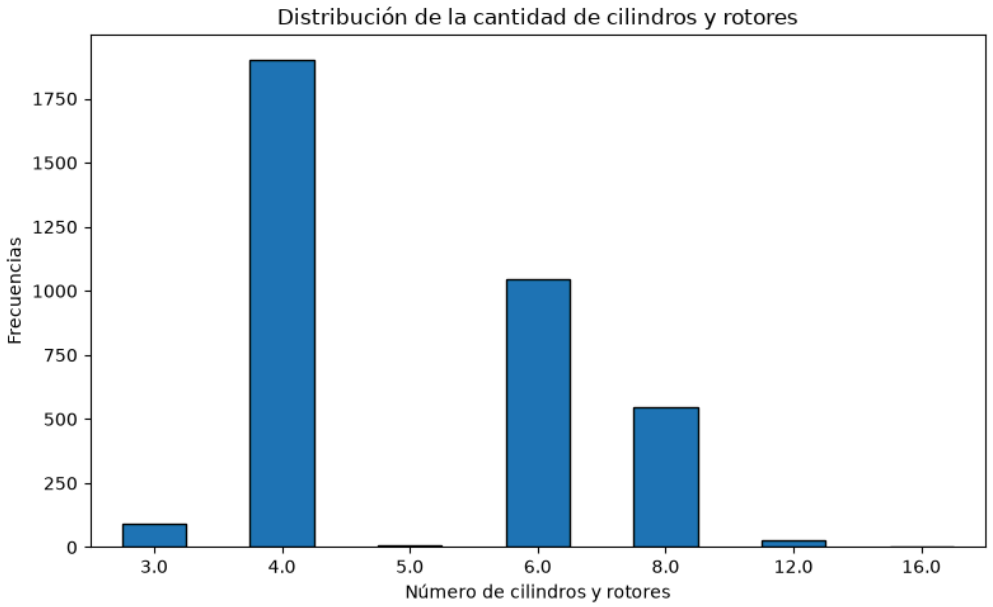
Observaciones: el análisis de esta variable revela una clara preferencia y dominancia de las tecnologías automáticas. Sin embargo las transmisiones manuales presentan una participación marginal y con frecuencias inferiores. Debido al marcado desbalance de clases y a la fragmentación de subcategorías específicas sugerimos aplicar un agrupamiento funcional de variables en bloques macro: automático, semiautomatico, CVT, Manual, otros, para evitar distorsiones estadísticas.

7. Test Fuel Type Description (Tipos de combustible)



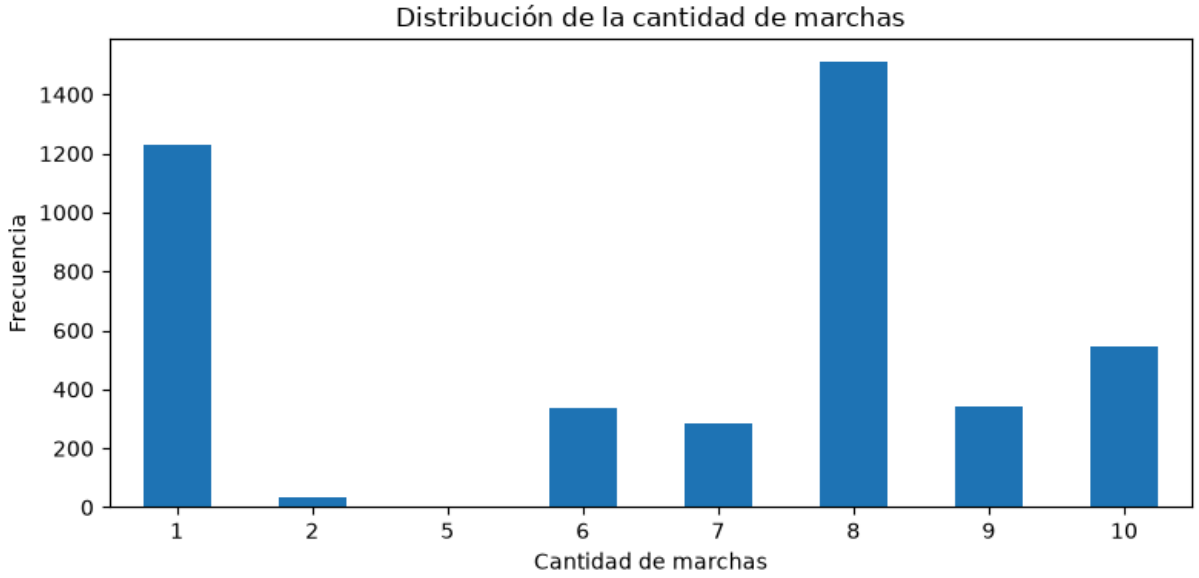
Observaciones: el conjunto está compuesto principalmente por configuraciones asociadas a “Tier 2 Cert Gasoline”, aunque también incluye vehículos eléctricos y otras categorías de combustible o condiciones de prueba. La variable requiere depuración ya que se identifica la presencia de categorías vacías que generan ruido en la visualización así como una fragmentación excesiva de subcategorías.

8. of Cylinder and Rotors (Cantidad de Cilindros)



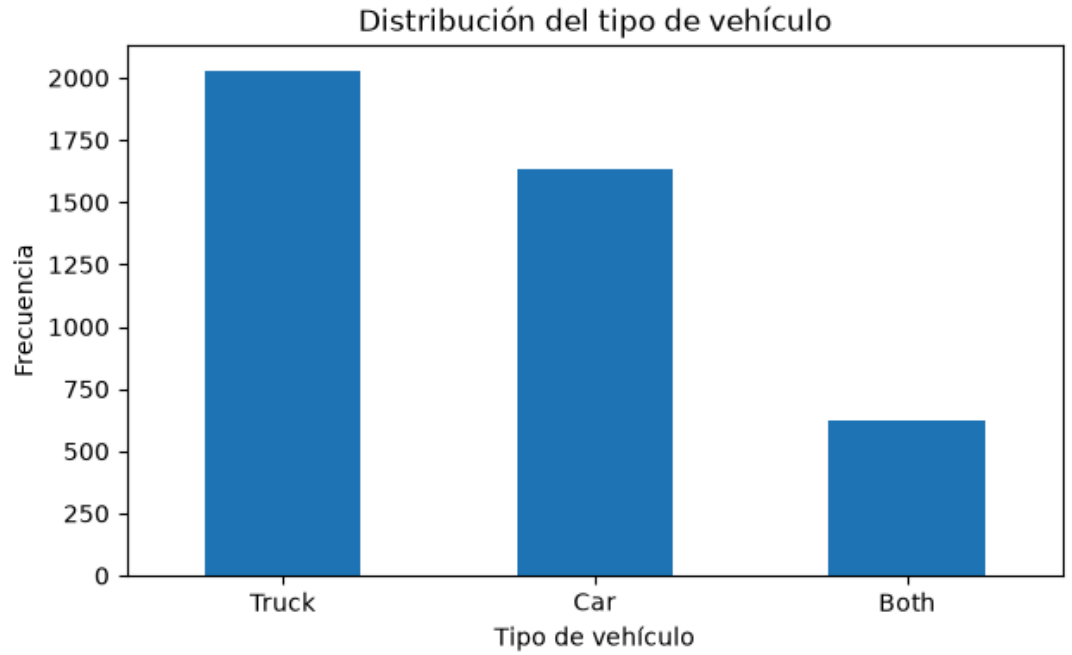
Observaciones: los valores se encuentran en un rango de 3 a 16 cilindros. La mayoría se concentra en 4 cilindros lo cual es el estándar de la industria automotriz global para autos de pasajeros, SUVs compactas y medianas. En el caso de los vehículos eléctricos esta variable es nula ya que no cuentan con cilindros.

9. # Of Gears (Cantidad de Marchas)



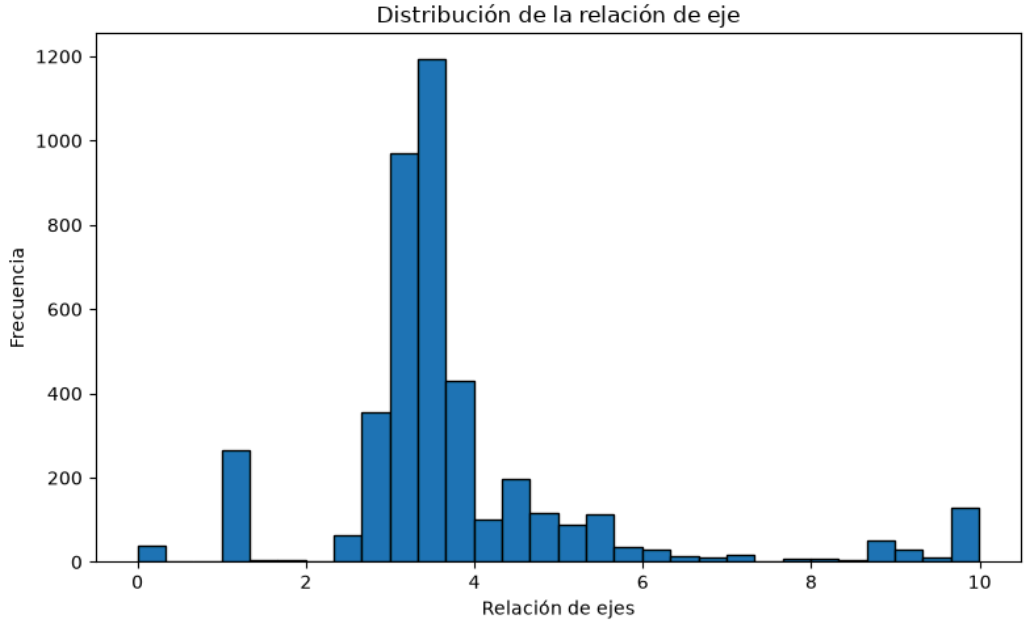
Observaciones: El valor 1 corresponde a la categoría donde se ubican las transmisiones de relación fija (eléctricos e hidrógeno) y a las cajas CVT continuas puras (sin marchas ficticias). Por su parte, la mayor frecuencia (1512 vehículos) corresponde a transmisiones de 8 marchas lo cual es normal en el mercado automotriz actual.

10. Vehicle Type (Tipo de Vehículo)



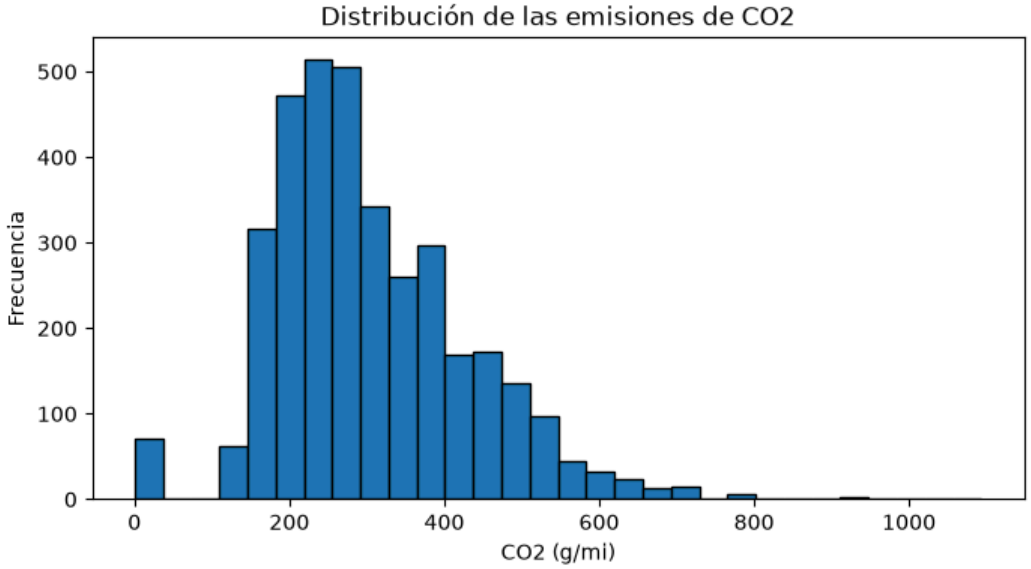
Observaciones: los valores se encuentran distribuidos en tres categorías principales: Truck que presenta la mayor frecuencia en el conjunto de datos, Car y Both. Consideramos que no es necesaria una limpieza en estos datos ya que no se visualizan valores atípicos.

11. Axle Ratio(Relación de Ejes)



Observaciones: los valores de la relación de ejes se concentran entre 2.5 y 4.0, rango típico para optimizar la eficiencia en vehículos livianos. Se observan valores extremos aislados cercanos a 1 para autos eléctricos y superiores a 9 para a configuraciones de trabajo pesado o transmisiones especiales. Analizaremos cómo vamos a tratar estos valores en el siguiente apartado.

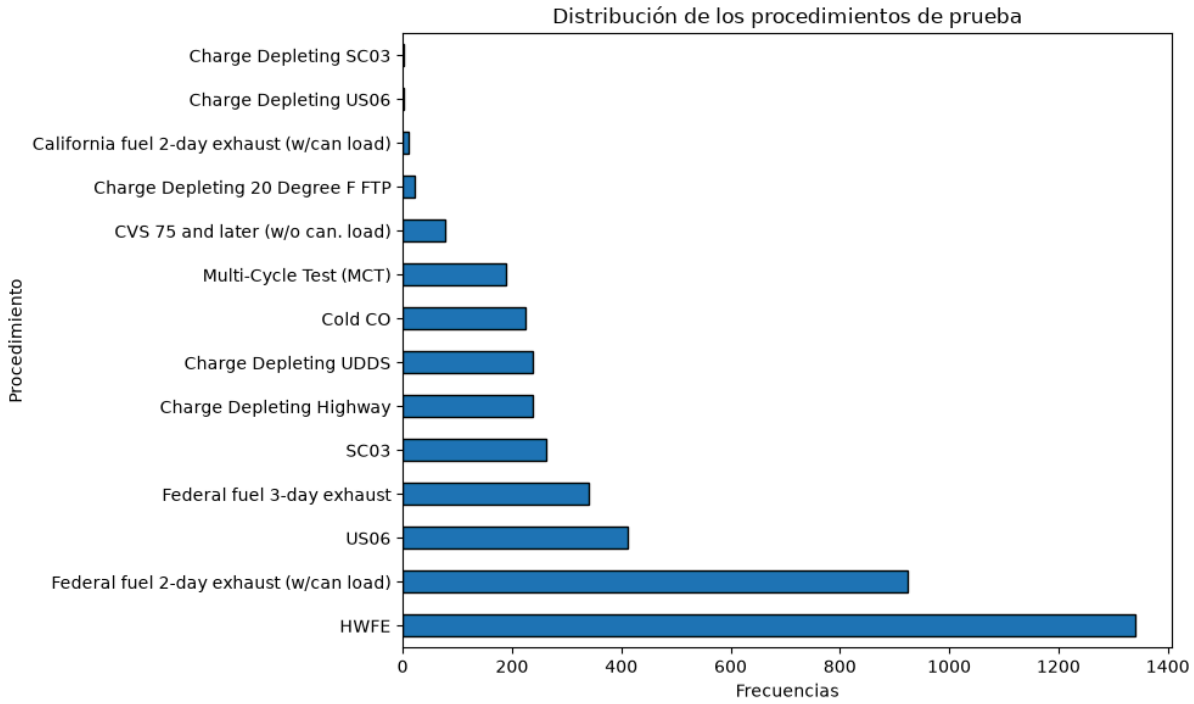
12. CO2 (Emisiones de CO2)



Observaciones: las emisiones de CO2 se concentran entre 200 y 400 g/mi, un rango habitual para vehículos de combustión convencionales. Se observa un grupo particular con valores cercanos a 0 g/mi, correspondiente a vehículos eléctricos o de cero emisiones, y

algunos valores altos dispersos que superan los 800 g/mi en configuraciones de alto rendimiento o trabajo pesado.

13. Test Procedure Description(Procedimientos de Prueba)



Observaciones: los procedimientos de prueba muestran una alta concentración en ciclos estándar como HWFE y ensayos de escape de varios días, reflejando las exigencias normativas principales de la EPA. Se observa una marcada disparidad con procedimientos específicos o de agotamiento de carga (charge depleting), los cuales presentan frecuencias significativamente menores o nulas al aplicarse únicamente a vehículos híbridos o eléctricos específicos.

---

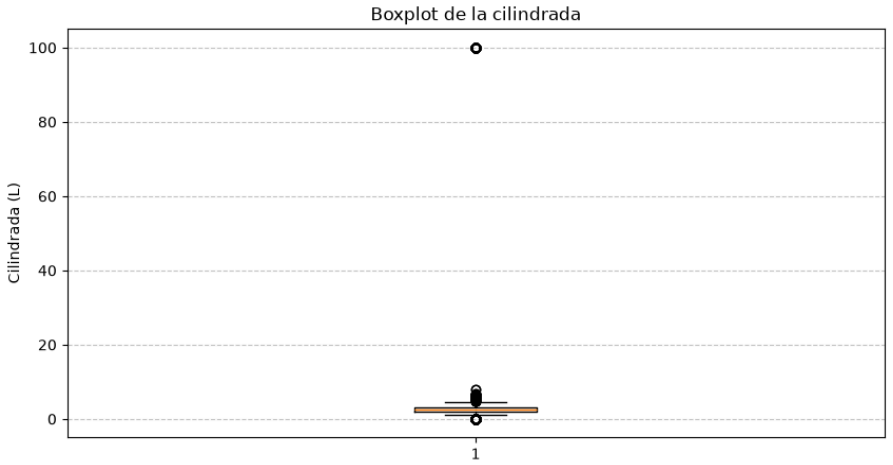
2. Limpieza de la base

En esta sección nos centramos en el proceso de tratamiento y depuración de la base de datos, con el objetivo de consolidar un conjunto listo para las pruebas de hipótesis.
Para preservar la información original, todas las modificaciones se realizan sobre una copia del dataset y con aquellas variables en las que encontramos inconsistencias en el apartado anterior.

Se utilizaron diagramas de caja (box plot) para identificar posibles valores atípicos. Estos valores se encuentran alejados de la distribución principal y dificultan su visualización si lo hacemos en gráficos de barras. Sin embargo, su detección estadística no permite afirmar por sí sola que sean outliers o centinelas. Por este motivo, se propone investigar los registros correspondientes y verificar su significado antes de decidir su tratamiento en la etapa de limpieza.

2.1. Limpieza de la variable Cilindrada:

En una primera instancia analizamos el boxplot correspondiente a la distribución de esta variable:

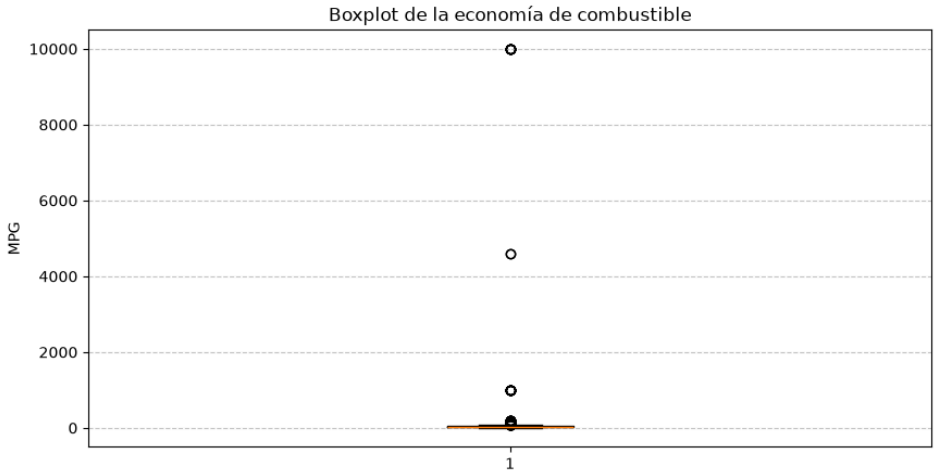


Análisis: podemos observar un valor cercano a 99.999 y otro de 0,001 litros extremadamente alejados de las demás observaciones, los cuales no representan un valor realista. Al revisar las filas, estos valores aparecen asociados a vehículos eléctricos lo cual nos indica que se trata de outliers artificiales.
Decidimos limpiar estos datos ya que afectan el promedio de manera drástica y distorsionan los resultados. Para eso contabilizamos cuantos valores nulos tenemos y los reemplazamos por NaN.

```
Nulos originales: 0
Nulos después de limpiar: 662
```

2.2. Limpieza de la Economía del Combustible

Analizamos el boxplot de la economía de combustible:



Análisis: podemos observar valores cercanos a 9999, y mayores a 4500 que son incompatibles con una medición habitual de MPG. También encontramos 999 que pertenecen a vehículos eléctricos o de hidrógeno, por lo que se trataría de un valor centinela. Para el caso donde es 0 se debe a que esta variable mide el combustible como un líquido y en casos como el hydrogen, pero medir la eficiencia de un vehículo de hidrógeno en millas por galón (mpg) es técnicamente incorrecto y poco útil.
Primero visualizamos cuántos de los datos corresponden a estos valores anteriormente mencionados:

Decidimos reemplazarlos por NaN en lugar de eliminar las filas completas, para que nuestros datos sean concisos y adecuados al tipo de variable con la que estamos trabajando.

```
Nulos originales: 0
Valores nulos despues de limpiar: 245
Valores iguales a 999: 0
Valores iguales a 9999.9999999: 0
Valores mayores a 1000: 0
```

2.3. Limpieza de la Potencia

Fueron encontrados registros con valor de 1 HP correspondientes a distintos procedimientos de prueba, el cual no es un número válido para esta variable. Esto sugiere que podría tratarse de un valor incorrecto o de un código especial en los datos.

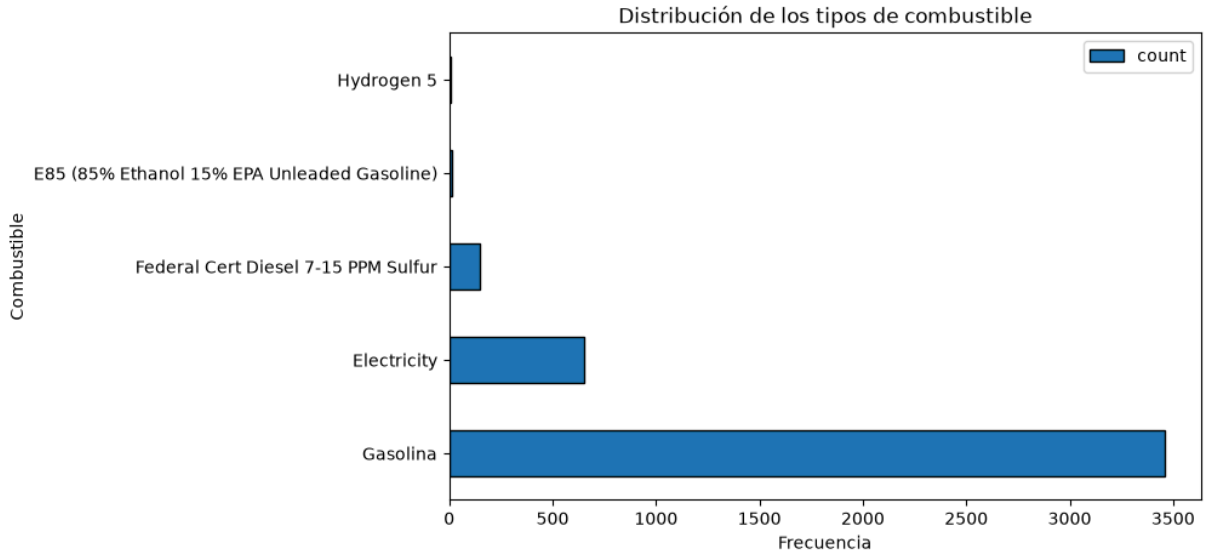
Decidimos reemplazar esos valores por NaN en df_limpio. La decisión se justifica porque
Los seis registros de los Ford Bronco Sport tienen motor de 1.5 L y funcionan con gasolina, por lo que una potencia nominal de 1 HP es incompatible con lo esperable.
Los 2 registros del Toyota Mirai también tienen 1 HP, y la cilindrada ya había sido identificada como un valor sospechoso antes de limpiarla.
Los ocho casos pertenecen a esos mismos tres modelos y no parecen ser valores aislados de distintos vehículos.

```
Valores nulos después del reemplazo: 8
Valores iguales a 1 después del reemplazo: 0
```

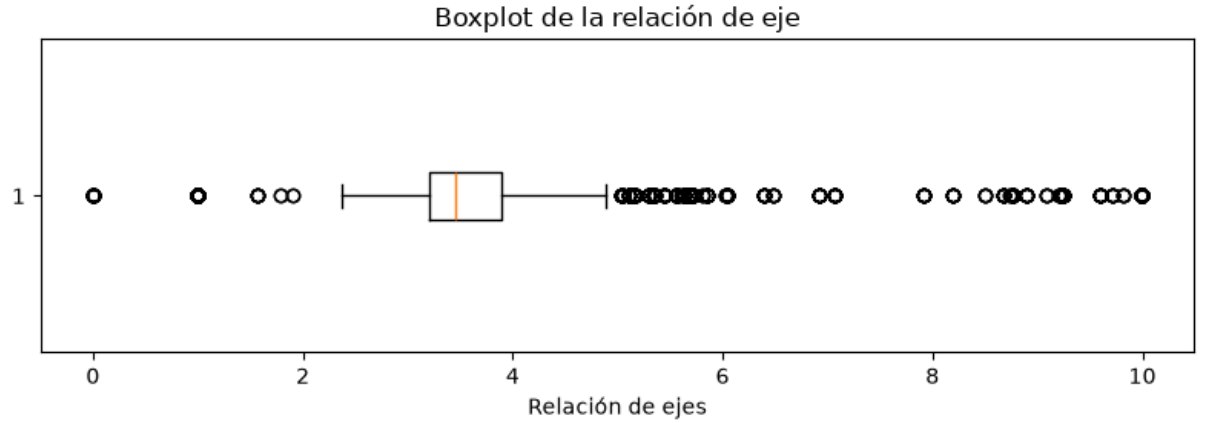
2.4. Limpieza de los Tipos de Combustible

Observamos que algunas categorías de la variable presentan una frecuencia muy baja. No eliminamos ni modificamos los valores originales ya que representan distintos tipos de

combustibles o especificaciones de las pruebas, pero para facilitar la visualización decidimos agrupar en diferentes variables las variantes de gasolina, las cuales predominan, manteniendo separadas las categorías correspondientes a electricidad, diésel, hidrógeno y E85. De esta manera se simplifica la representación de los datos sin perder la información original, facilitandonos así la lectura.



2.5. Limpieza de la Relación de Ejes



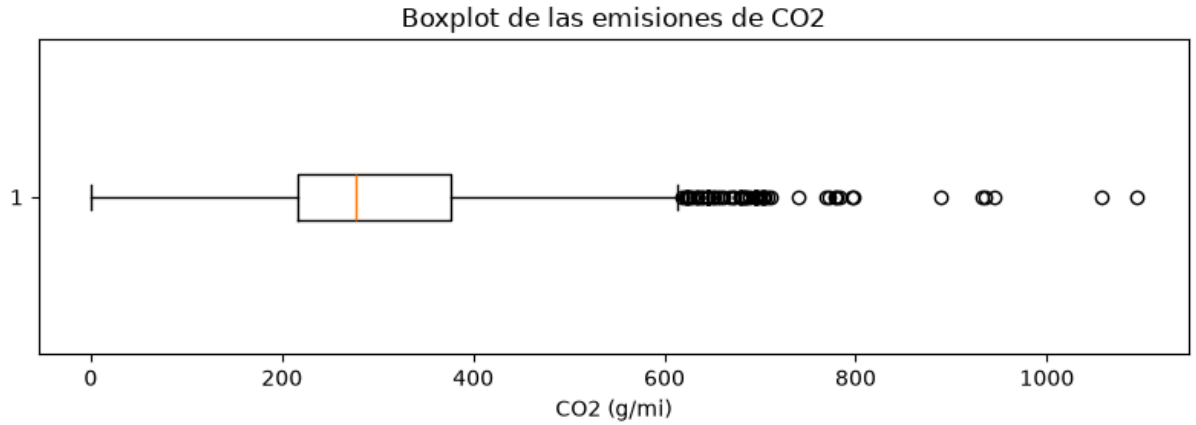
En base al boxplot de la relación de eje, analizamos los valores outliers: entre 0 y 1 y los cercanos a 10.

La variable cuenta con un total de 38 valores iguales a 0 que cuando los analizamos en detalle nos damos cuenta de que corresponden a vehículos eléctricos y de hidrógeno (como Nissan Ariya y Toyota RZ 300e).
Nuestra hipótesis es que en consecuencia de que los autos eléctricos no cuentan con el sistema de eje tradicional de un auto a gasolina los fabricantes apuntaron 0 o 1 en esa variable. Basándonos en eso, no tomamos estos valores como errores, sino como una notación diferenciadora y decidimos reemplazarlos por NaN en df_limpio.

```
Nulos en Axle Ratio antes: 0
Valores iguales a 0 antes: 38

Nulos en Axle Ratio ahora: 38
Valores iguales a 0 ahora: 0
```

2.6. Limpieza de las emisiones de CO2



Una vez visualizado el boxplot de esta variable analizamos sus outliers, los cuales pertenecen al rango desde 600 g/mi a valores mayores a 1000 g/mi.
Obtuvimos que existen 71 filas con esta variable en cero, las cuales corresponden a vehículos eléctricos pero decidimos conservarlos e investigar los valores del rango mencionado anteriormente.

	Vehicle Manufacturer Name	Represented Test Veh Model	Test Fuel Type Description	CO2 (g/mi)
357	BMW	M5 Sedan	Tier 2 Cert Gasoline	1093.643465
371	BMW	M5 Touring	Tier 2 Cert Gasoline	1057.074100
360	BMW	M5 Sedan	Cold CO Premium (Tier 2)	945.157600
4116	Volkswagen Group of	Bugatti Pur Sport	Tier 2 Cert Gasoline	935.000000
372	BMW	M5 Touring	Cold CO Premium (Tier 2)	931.824900
492	BMW	XM Label	Cold CO Premium (Tier 2)	888.765003

Los seis valores más altos que encontramos corresponden a vehículos de combustión. Sus emisiones pertenecen al rango de 889g/mi a 1094 g/mi.

No tenemos evidencia suficiente para afirmar que se trata de errores de tipeo o fallos en los datos, sino de valores atípicos resultantes de combinaciones en la prueba. El hecho de que sean valores atípicos no justifica reemplazarlos por NaN.

2.7. Limpieza de la distribución de los Procedimientos de prueba

```
Procesos de Prueba
Nulos: 0
Cantidad de procedimientos: 14

Test Procedure Description
HWFE                                        1340
Federal fuel 2-day exhaust (w/can load)      923
US06                                         412
Federal fuel 3-day exhaust                   341
SC03                                         263
Charge Depleting Highway                     239
Charge Depleting UDDS                        237
Cold CO                                      224
Multi-Cycle Test (MCT)                       190
CVS 75 and later (w/o can. load)              78
Charge Depleting 20 Degree F FTP              23
California fuel 2-day exhaust (w/can load)    11
Charge Depleting US06                          3
Charge Depleting SC03                          3
Name: count, dtype: int64
```

No hay nulos ni outliers y existen un total de catorce categorías. Las categorías poco frecuentes parecen ser procedimientos específicos, por lo que no hace falta agruparlas ni eliminarlas.

2.8. Limpieza de NULOS

Con respecto a las variables que presentaban datos ausentes desde el origen del dataset, se analizó cada caso particular para aplicar el procedimiento de limpieza y de imputación adecuado. En una primera instancia, se identificaron las columnas con valores nulos, constatando que solo 3 de las 13 variables seleccionadas los contenían: CO2, #of Cylinders and Rotors y RND_ADJ_FE. A continuación, detallamos el análisis individual y las decisiones adoptadas para cada una de ellas.

	Nulos originales	Nulos después de limpiar	Nulos generados	Porcentaje actual (%)
CO2 (g/mi)	724	724	0	16.89
# of Cylinders and Rotors	670	670	0	15.63
Test Veh Displacement (L)	0	662	662	15.44
RND_ADJ_FE	221	245	24	5.71
Axle Ratio	0	38	38	0.89
Rated Horsepower	0	8	8	0.19
Equivalent Test Weight (lbs.)	0	0	0	0.00
# of Gears	0	0	0	0.00
Tested Transmission Type	0	0	0	0.00
Test Fuel Type Description	0	0	0	0.00
Drive System Description	0	0	0	0.00
Vehicle Type	0	0	0	0.00
Test Procedure Description	0	0	0	0.00

2.8.1. Nulos en la Cantidad de Cilindros.

```
Test Fuel Type Description
Electricity                                  100.00
Hydrogen 5                                   100.00
Tier 2 Cert Gasoline                           0.19
Cold CO E10 Regular Gasoline (Tier 3)          0.00
CARB LEV3 E10 Regular Gasoline                 0.00
CARB LEV3 E10 Premium Gasoline                 0.00
Cold CO Premium (Tier 2)                       0.00
E85 (85% Ethanol 15% EPA Unleaded Gasoline)    0.00
Cold CO Regular (Tier 2)                       0.00
Federal Cert Diesel 7-15 PPM Sulfur            0.00
Tier 3 E10 Regular Gasoline (9 RVP @Low Alt.)  0.00
Name: # of Cylinders and Rotors, dtype: float64
```

La tabla indica que los 670 nulos de # of Cylinders and Rotors están concentrados en dos tipos de combustible: vehículos eléctricos e hidrógeno.
Estos registros carecen del número de cilindros lo cual es consistente con la especificación de la columna, orientada únicamente a registrar las características de motores de combustión tradicional.
Un porcentaje menor corresponde a la gasolina de la cual tenemos seis registros sin el dato, mientras que casi todos los demás sí lo tienen.

Se investigaron los seis registros sin información de cilindros que utilizan gasolina. Estos corresponden a dos BMW 230i Coupe y cuatro Mazda CX-5, cuyos valores de cilindrada y potencia sí están informados. Como no se dispone de información suficiente para determinar con certeza la cantidad de cilindros de cada registro, se decidió conservar los valores faltantes sin reemplazarlos ni eliminar las filas.

2.8.2. Nulos en emisiones de CO2

CO2 (g/mi)	False	True	All
Test Fuel Type Description			
CARB LEV3 E10 Premium Gasoline	2	0	2
CARB LEV3 E10 Regular Gasoline	1	0	1
Cold CO E10 Regular Gasoline (Tier 3)	2	0	2
Cold CO Premium (Tier 2)	57	0	57
Cold CO Regular (Tier 2)	160	0	160
E85 (85% Ethanol 15% EPA Unleaded Gasoline)	12	0	12
Electricity	70	584	654
Federal Cert Diesel 7-15 PPM Sulfur	150	0	150
Hydrogen 5	0	10	10
Tier 2 Cert Gasoline	3106	130	3236
Tier 3 E10 Regular Gasoline (9 RVP @Low Alt.)	3	0	3
All	3563	724	4287

De los 724 nulos existentes en esta variable, 584 corresponden a vehículos eléctricos y 10 a los registros existentes de hidrógeno.

En el caso de la gasolina, tenemos 130 registros faltantes los cuales no coinciden con lo esperable en este tipo de combustible, que sí debería tener emisiones de CO2.
Cuando analizamos detenidamente este caso, obtuvimos que estos registros corresponden a 53 modelos diferentes y a procedimientos de tipo Charge Depleting UDDS y Charge Depleting Highway, ambos con todos sus registros sin valores.
Estos ensayos evalúan vehículos híbridos enchufables operando en modo 100% eléctrico (agotamiento de batería), fase en la que el motor de combustión permanece inactivo y no genera emisiones directas.

```
Cantidad de registros: 130
Cantidad de modelos diferentes: 53
```

	Vehicle Manufacturer Name	Represented Test Veh Model	Test Procedure Description	Test Fuel Type Description	CO2 (g/mi)
107	BMW	550e xDrive Sedan	Charge Depleting UDDS	Tier 2 Cert Gasoline	NaN
108	BMW	550e xDrive Sedan	Charge Depleting Highway	Tier 2 Cert Gasoline	NaN
120	BMW	750e xDrive Sedan	Charge Depleting UDDS	Tier 2 Cert Gasoline	NaN
121	BMW	750e xDrive Sedan	Charge Depleting Highway	Tier 2 Cert Gasoline	NaN
358	BMW	M5 Sedan	Charge Depleting UDDS	Tier 2 Cert Gasoline	NaN
...	...	...	...	...	...
4241	Volvo	S90 T8 AWD Recharge Extended Range	Charge Depleting Highway	Tier 2 Cert Gasoline	NaN
4251	Volvo	XC60 T8 AWD Recharge Extended Range	Charge Depleting Highway	Tier 2 Cert Gasoline	NaN
4254	Volvo	XC60 T8 AWD Recharge Extended Range	Charge Depleting UDDS	Tier 2 Cert Gasoline	NaN
4259	Volvo	XC90 T8 AWD Recharge	Charge Depleting Highway	Tier 2 Cert Gasoline	NaN
4260	Volvo	XC90 T8 AWD Recharge	Charge Depleting UDDS	Tier 2 Cert Gasoline	NaN

Este patrón sugiere que la ausencia de información está relacionada con las características de los procedimientos de prueba. Como no se dispone de evidencia suficiente para determinar un valor correcto para los datos faltantes, se decidió conservarlos como NaN, sin imputarlos ni eliminar las filas.

2.8.3. Nulos de la Economía del Combustible.

RND_ADJ_FE	False	True	All
Test Fuel Type Description			
CARB LEV3 E10 Premium Gasoline	2	0	2
CARB LEV3 E10 Regular Gasoline	1	0	1
Cold CO E10 Regular Gasoline (Tier 3)	2	0	2
Cold CO Premium (Tier 2)	57	0	57
Cold CO Regular (Tier 2)	160	0	160
E85 (85% Ethanol 15% EPA Unleaded Gasoline)	12	0	12
Electricity	563	91	654
Federal Cert Diesel 7-15 PPM Sulfur	150	0	150
Hydrogen 5	10	0	10
Tier 2 Cert Gasoline	3106	130	3236
Tier 3 E10 Regular Gasoline (9 RVP @Low Alt.)	3	0	3
All	4066	221	4287

Obtuvimos que 91 registros nulos de la variable corresponden a autos eléctricos y están distribuidos entre cinco procedimientos de ensayo. Los faltantes responden a la naturaleza tecnológica del vehículo y no a una falla circunstancial de medición.

Por otro lado tenemos 130 registros correspondientes a gasolina que corresponden en su totalidad a procedimientos Charge Depleting, 65 de cada uno. Esto coincide con el patrón que encontramos al investigar los nulos de CO2 anteriormente.
Estos patrones sugieren que la ausencia de información podría estar relacionada con las características de los ensayos.
Sin embargo, no se dispone de evidencia suficiente para determinar los valores faltantes, por lo que decidimos conservarlos como NaN, sin imputarlos ni eliminar las filas.

2.9. Filas Duplicadas

Investigamos la existencia de filas completamente duplicadas en el conjunto de datos mediante el método duplicated(), obteniendo un resultado de cero filas duplicadas, por lo que no fue necesario eliminar ningún registro en esta etapa.

---

3. Planteo de hipótesis

3.1. Hipótesis univariada

Formulación de la hipótesis: la distribución de la potencia (Rated Horsepower) nominal de los vehículos presenta asimetría hacia la derecha (positiva): la mayoría de las pruebas se concentran en un rango moderado, entre los 200 HP y 400 HP, mientras que una minoría de vehículos de alto rendimiento alcanza valores extremos de hasta 1,000 HP.

3.2. Hipótesis bivariada

Formulación de la hipótesis: existe una relación lineal directa y positiva entre el peso del vehículo (Equivalent Test Weight) y sus emisiones de dióxido de carbono (CO2 (g/mi)), de manera que a mayor masa asignada para la prueba, mayor es la cantidad de CO_2 emitida por milla recorrida en los vehículos de combustión interna.

3.3. Hipótesis multivariada

Formulación de la Hipótesis: la economía de combustible ajustada de los vehículos (Y) se encuentra asociada conjuntamente con sus características técnicas y mecánicas (X) existiendo una relación inversamente proporcional con el peso, la potencia, la cilindrada, la cantidad de cilindros, el tipo de transmisión y el sistema de tracción.

---

4. Validación de las Hipótesis

4.1. Validación de la Hipótesis Univariada

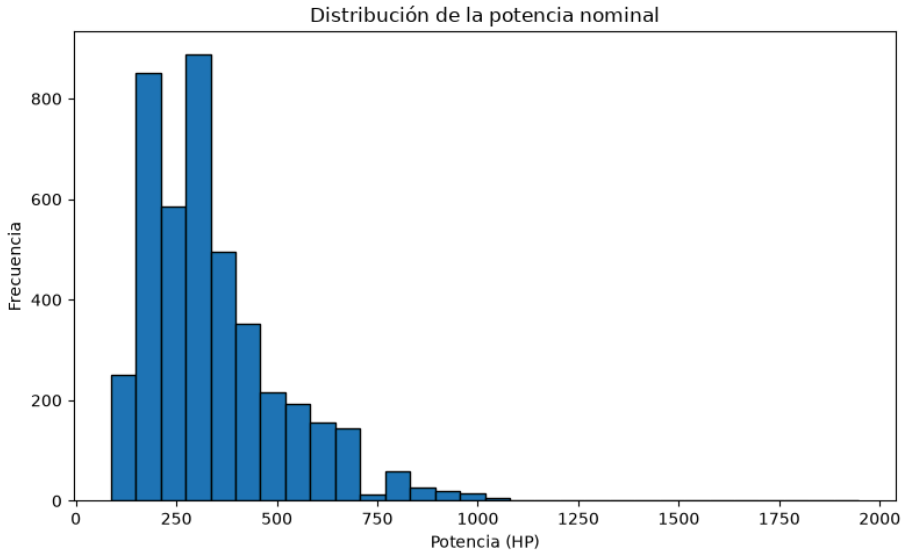
En esta sección se analiza la distribución de la potencia nominal de los vehículos, con el objetivo de identificar si presenta una asimetría hacia la derecha (positiva). Para ello, se utilizan medidas estadísticas como la media, la mediana y el coeficiente de asimetría, complementando el análisis con representaciones gráficas que permiten observar la distribución de los valores y la presencia de posibles valores extremos.

Análisis:
Para complementar la inspección visual de los gráficos, se calcularon las medidas de tendencia central (media y mediana) y la asimetría de la variable, debido a que al compararlas podemos determinar de forma inmediata si la distribución es simétrica o si está sesgada por la presencia de vehículos con características extremas.
Cabe destacar que, durante la fase de limpieza de datos, los registros atípicos erróneos (como los valores de 1 HP) fueron tratados como nulos. Al utilizar las funciones de cálculo agregadas sobre la columna depurada, los valores nulos son ignorados automáticamente, garantizando que el análisis estadístico refleje con precisión la estructura real de los datos sin distorsiones.

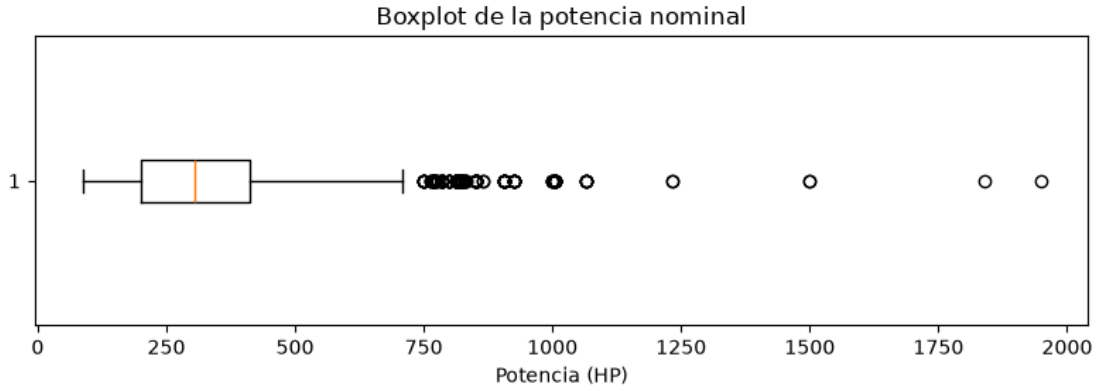
```
Media: 341.3332554335125
Mediana: 305.0
Asimetría: 1.6076685431878754

count    4279.000000
mean      341.333255
std       174.667461
min        87.000000
25%       201.000000
50%       305.000000
75%       412.000000
max      1948.000000
Name: Rated Horsepower, dtype: float64
```

La media superior a la mediana y la asimetría positiva son consistentes con una distribución sesgada hacia la derecha.
Graficamos la variable con un histograma ya que nos permite inspeccionar visualmente la modalidad de la distribución, confirmar la dirección del sesgo detectado por la asimetría, y contrastar directamente la posición relativa de la media y la mediana dentro de la curva. Como resultado obtuvimos una concentración de observaciones en valores moderados y una disminución de las frecuencias a medida que aumenta la potencia.



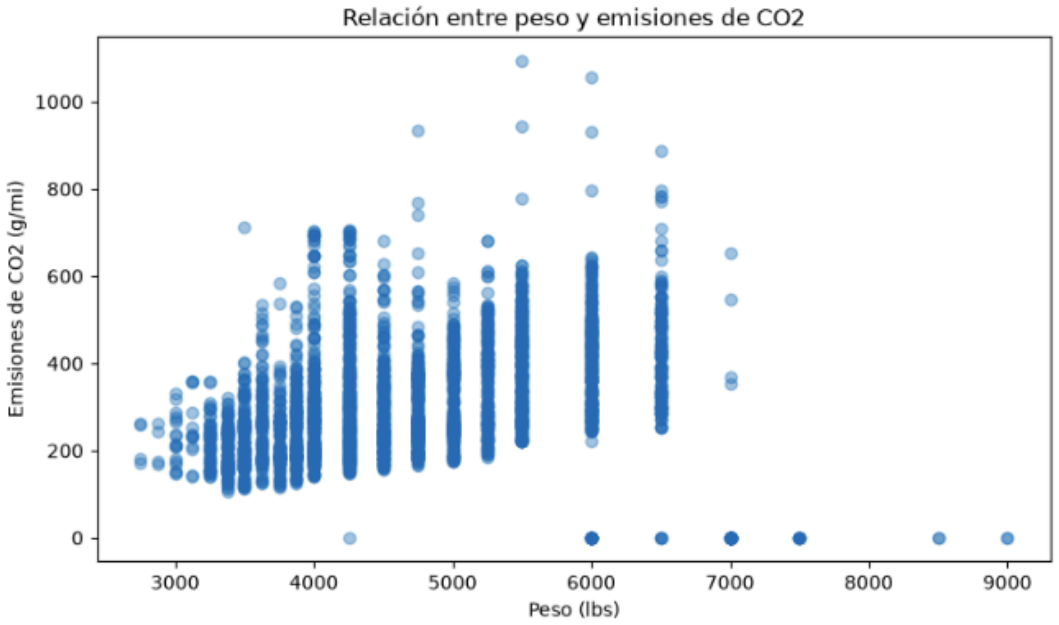
Por su parte, utilizamos un boxplot que nos permite identificar de forma objetiva los valores atípicos permitiendo evaluar la dispersión y la simetría de los cuartiles sin asumir normalidad en los datos. Se identifican observaciones de potencia elevada que se alejan del rango central.



Los resultados descriptivos respaldan la hipótesis planteada: los valores elevados se conservan, ya que ser atípicos no implica necesariamente que sean incorrectos, sino que corresponden a determinados ensayos aislados.

4.2. Validación de la Hipótesis Bivariada

Para evaluar esta hipótesis trabajamos con las variables Equivalent Test Weight y CO2 (g/mi).
Utilizamos un gráfico de dispersión ya que es la herramienta de visualización bivariada fundamental para explorar dos variables cuantitativas continuas que representan magnitudes físicas reales.



La eliminación previa de la subpoblación de vehículos de cero emisiones resultó indispensable para evitar la distorsión del coeficiente de correlación paramétrico de la muestra global.

Por su parte, calculamos el coeficiente de correlación de Pearson, para medir la fuerza y dirección de la asociación lineal entre las variables, y el coeficiente de Spearman, para evaluar la asociación monótona basada en rangos al ser una técnica no paramétrica y robusta frente a no linealidades o valores extremos:

```
Cantidad de registros analizados: 3563
Correlación de Pearson: 0.317
Correlación de Spearman: 0.449
```

Para llevar a cabo este cálculo y la visualización bivariada, aplicamos un filtro de selección mediante dropna() sobre el par de variables analizadas ya que cada observación requiere disponer simultáneamente del dato de peso y de emisiones para ser ubicada con precisión en el gráfico de dispersión y ser considerada en el planteo de las métricas de correlación. Este procedimiento no altera la estructura general del dataset limpio, sino que genera un subconjunto de trabajo específico para este análisis bivariado.

Análisis de la correlación de Pearson(0,317):
Refleja una asociación lineal directa (positiva) de fuerza moderada-baja. Confirma que a mayor peso existe una tendencia general al aumento de emisiones, aunque una recta no explica por sí sola toda la variabilidad de los datos.

Análisis de la correlación de Spearman (0,449):
Muestra una asociación monótona de fuerza moderada. Al ser mayor que Pearson demuestra que la relación ascendente es más firme en rangos y que la métrica paramétrica se ve afectada por la discretización del peso y la presencia de valores atípicos.
Conclusión:

A partir del análisis del gráfico de dispersión y los valores resultantes de las correlaciones se cumple la hipótesis que propusimos. Se confirma la existencia de una relación lineal directa de fuerza positiva moderada entre el peso asignado al vehículo (Equivalent Test Weight) y sus emisiones directas de CO2 por milla recorrida. El peso actúa como un factor determinante para un mayor volumen de emisiones.

4.3. Validación de la Hipótesis Multivariada

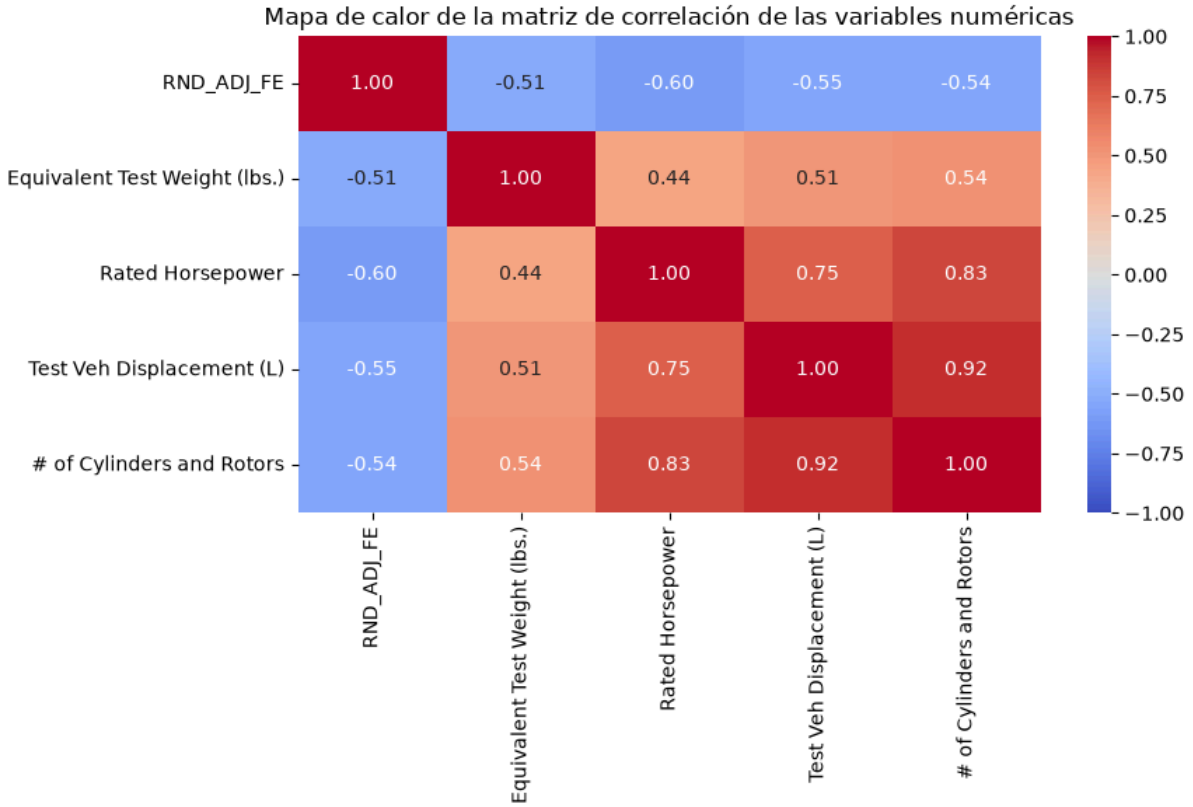
Variables involucradas:

Cuantitativas continuas:

- Equivalent Test Weight (Peso).
- Rated Horsepower (Potencia).
- Test Veh Displacement (Cilindrada).
- RND_ADJ_FE (Economia del Combustible).
- # of Cylinders and Rotors (Cantidad de Cilindros).
- Drive System Description (Sistema de Tracción).
- Tested Transmission Type (Tipo de Transmisión).

Análisis de la relación entre las variables cuantitativas:

Se construyó una matriz de correlaciones utilizando el coeficiente de Pearson. Esta técnica permite medir la intensidad y dirección de las relaciones lineales entre las variables cuantitativas.



Los resultados respaldan parcialmente nuestra hipótesis: en los datos analizados, los vehículos con mayor peso, potencia, cilindrada y cantidad de cilindros tienden a presentar menores valores de MPG.

Por lo tanto, las cuatro variables cuantitativas muestran una asociación negativa con la economía de combustible, en conformidad con lo planteado en la hipótesis.

Regresión lineal múltiple:
Con el propósito de evaluar nuestra hipótesis multivariada, se ajustó un modelo de regresión lineal múltiple que expresa el rendimiento de combustible (Y, medido en MPG) en función de un conjunto de predictores:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \varepsilon$$

Este enfoque permite estudiar el efecto propio de cada parámetro técnico sobre la eficiencia sin los sesgos derivados del análisis bivariado aislado.

Hipótesis nula (H0): la economía de combustible no presenta una asociación lineal significativa con el conjunto de características técnicas y mecánicas consideradas.

$$H0: \beta_1 = \beta_2 = \cdots = \beta_{14} = 0$$

Hipótesis alternativa (H1): la economía de combustible presenta una asociación lineal significativa con el conjunto de características técnicas y mecánicas consideradas.

$$H1: Al\ menos\ un\ \beta_j \neq 0$$

Transformar las variables cualitativas

Debido a que la regresión lineal trabaja con valores numéricos no podemos pasarle directamente categorías como Automatic o 2-Wheel Drive, Rear.

Para solucionar esto utilizamos la técnica One-Hot Encoding, que transforma cada categoría en una columna numérica y obtenemos 14 variables explicativas: cuatro cuantitativas y diez columnas indicadoras.

Análisis de los resultados de la Regresión Lineal Múltiple:

A diferencia del mapa de calor que nos indica la relación de a pares, la correlación que vemos en el modelo de regresión contempla qué pasa cuando todas las variables actúan al mismo tiempo en el auto.

El modelo presenta una asociación conjunta estadísticamente significativa entre la economía de combustible y las características técnicas y mecánicas consideradas, explicando en conjunto el 51% de su variabilidad (R^2 = 0.510).

La validez global de esta relación se justifica mediante dos métricas clave:

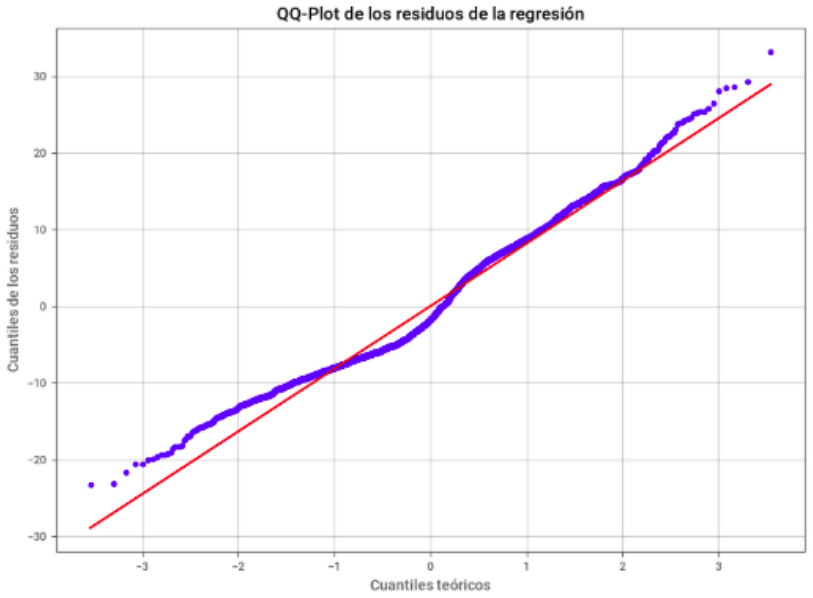
- Estadístico FFF (257.4): evalúa la solidez del modelo. Un valor tan elevado confirma que estas variables explican el consumo de forma real y no por simple coincidencia.
- P-valor (Prob F < 0.001): Es el margen de error. El p-valor obtenido en la prueba F fue inferior a 0,001. Existe evidencia estadística suficiente para afirmar que las características técnicas y mecánicas consideradas, tomadas en conjunto, están relacionadas con la economía de combustible de los vehículos. Por lo tanto, rechazamos la hipótesis nula, que planteaba que no existía una asociación lineal entre MPG y el conjunto de variables explicativas.

El análisis del modelo confirma la relación inversamente proporcional planteada en la hipótesis para las principales variables físicas continuas: peso (coef = -0.0032), potencia (coef = -0.0301) y cilindrada (coef = -3.5008), todas con una significancia estadística contundente($p < 0,001$).

En términos concretos, a mayor masa del vehículo o mayor tamaño y potencia del motor, menor es la cantidad de millas recorridas por galón (RND_ADJ_FE).

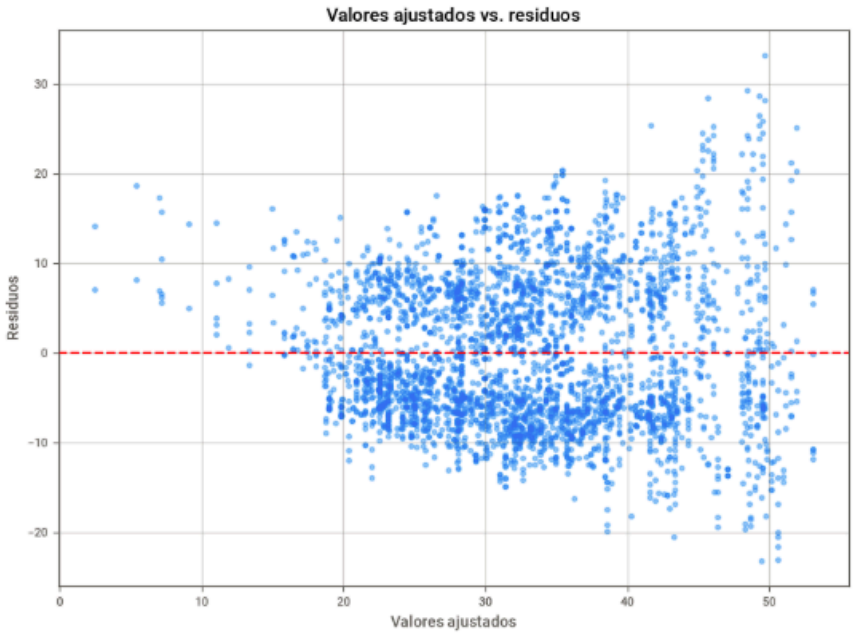
Diagnóstico de residuos:

- QQ-Plot de residuos (Evaluación de distribución normal):



Este gráfico nos sirve para verificar si los errores del modelo de regresión siguen una distribución normal. Podemos ver que los datos se ajustan correctamente a la línea central, lo que valida el comportamiento general del modelo. Sin embargo, en las colas los puntos se desvían, alejándose de la norma lineal, evidenciando la presencia de outliers.

- Valores ajustados vs. Residuos (evaluación de varianza constante):



Los errores muestran una varianza constante únicamente en la zona central (vehículos de consumo medio). Sin embargo, la dispersión se vuelve irregular en ambos extremos: en los vehículos de bajo rendimiento (0 a 15 MPG) los puntos aparecen aislados con desvíos considerables, mientras que a partir de los 40 MPG la dispersión se abre marcadamente en forma de abanico. Esta variabilidad no constante en los extremos confirma la presencia de heterocedasticidad, lo que indica que el modelo pierde precisión predictiva tanto en vehículos de consumo extremo como en los hiper-eficientes.

4.3.5 Clustering

Con clustering buscamos identificar grupos de vehículos con características técnicas similares para poder observar si presentan diferentes niveles de economía de combustible.
Se eligió dividir el dataset en 5 clusters porque fue la cantidad que logró el coeficiente de silueta más alto (0.4334), garantizando grupos bien definidos entre sí.
Los resultados obtenidos mediante la segmentación no supervisada respaldan parcialmente la hipótesis planteada: se ratifica de forma directa la relación inversamente proporcional para la masa, la potencia y la cilindrada, observándose una caída sistemática en el rendimiento promedio desde 43.94 MPG (Cluster 1) hasta 27.19 MPG (Cluster 4). Por otro lado, la transmisión, la tracción y la cantidad de cilindros no cambian el consumo siguiendo una línea recta, más bien funcionan como decisiones de diseño o tecnología que aumentan o bajan la eficiencia según el tipo de auto.

Conclusión:

A partir de los análisis realizados, se encontró evidencia estadística de que la economía de combustible ajustada de los vehículos se encuentra asociada conjuntamente con sus características técnicas y mecánicas. La regresión lineal múltiple presentó un R^2 de 0,510 y una prueba F estadísticamente significativa, lo que permitió rechazar la hipótesis nula de ausencia de asociación conjunta. En cuanto a las variables cuantitativas, el peso, la potencia y la cilindrada presentaron coeficientes negativos, en concordancia con lo

esperado, mientras que la cantidad de cilindros presentó un coeficiente positivo, contrario a la relación planteada inicialmente.

Por otra parte, las variables cualitativas de tipo de transmisión y sistema de tracción también fueron incorporadas al modelo mediante One-Hot Encoding, lo cual nos permitió identificar diferencias entre categorías con respecto a la economía del combustible, pero no todas significativas.

El análisis de clustering complementó estos resultados, mostrando que los grupos de vehículos con mayores valores de potencia, cilindrada y cantidad de cilindros tendieron a presentar menores niveles de economía de combustible.

En conclusión, los resultados respaldan la existencia de una asociación conjunta entre las características técnicas y mecánicas de los vehículos y su economía de combustible. Sin embargo, la relación inversa planteada inicialmente no se cumple de manera uniforme para todas las variables. Por este motivo, consideramos que la hipótesis recibe un respaldo parcial.

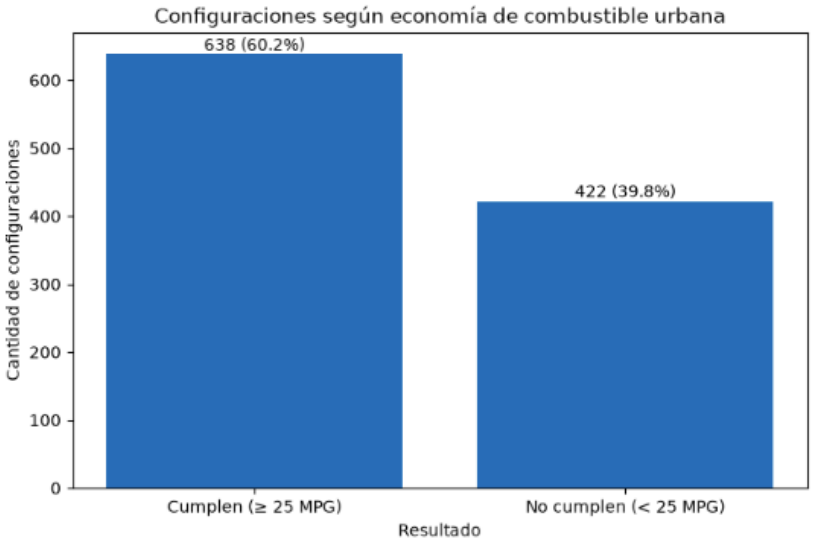
4.4. Validación de las Hipótesis planteadas por la cátedra

a) *"La mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG de economía de combustible en condiciones de conducción urbana."*

Análisis:
Se trata de un análisis univariado que estudia si la configuración realizada alcanza o no los 25 MPG.

- Variable: cumplimiento del umbral de 25 MPG.
- Parámetro p: proporción de configuraciones que alcanzan al menos 15 MPG.
- H0: p <= 0,50.
- H1: p > 0,50.

Filtramos por la variable Test Category (FTP), como indicador de economía urbana. Indica el ciclo de manejo en ciudad (paradas frecuentes, aceleraciones, etc).



Conclusión:

Se analizaron 1060 configuraciones de vehículos a combustión, de las cuales 638 (más del 60%) alcanzaron una economía de combustible de al menos 25 MPG. Dado que este porcentaje supera el 50% los resultados respaldan la hipótesis planteada.

b) *"En vehículos de combustión, la economía de combustible difiere según el sistema de tracción del vehículo."*

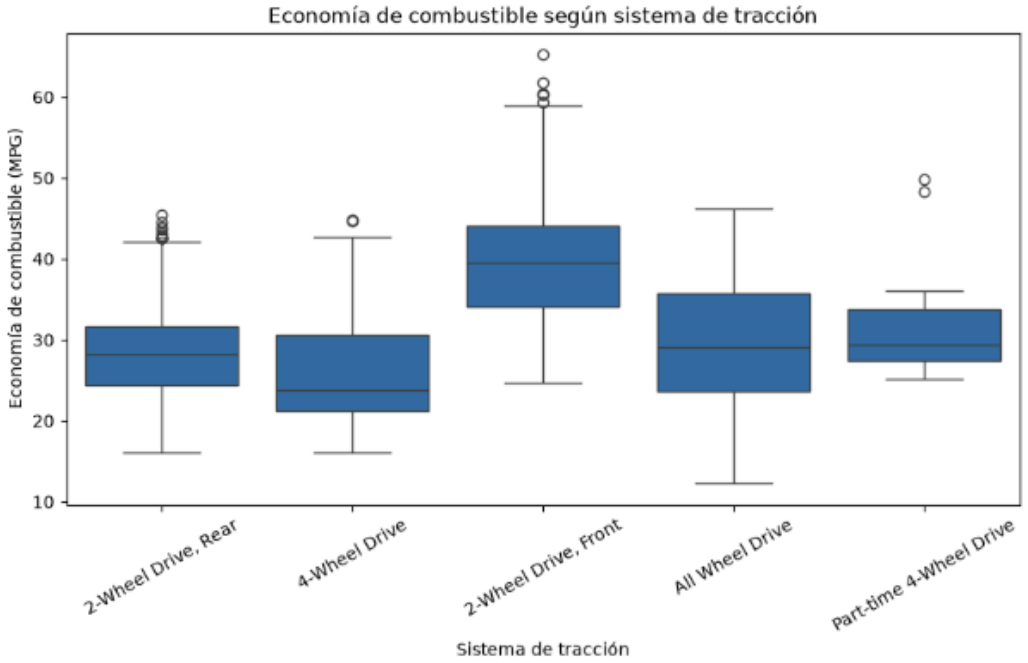
Para realizar el análisis bivariado que se nos presenta en la hipótesis consideramos las siguientes variables, H0, H1 y nivel de significancia:

- Variable independiente: Drive System Description (Sistema de Tracción), de tipo cualitativa nominal.
- Variable dependiente: RND_ADJ_FE (Economia del Combustible), de tipo cuantitativa.
- H0: la distribución de la economía de combustible es equivalente entre los distintos sistemas de tracción en los vehículos de combustión interna.
- H1: la distribución de la economía de combustible difiere significativamente entre al menos dos sistemas de tracción en los vehículos de combustión interna.
- Nivel de significancia prefijado: 95%.

Estrategia de análisis:

Agrupamos los datos por registros que tienen la misma configuración de vehículo considerando que un mismo auto puede tener múltiples pruebas en la base. Luego, al calcular el promedio por vehículo nos queda cada auto una sola vez y allí podemos evaluar las configuraciones únicas, que es lo que nos pide la consigna.

Utilizamos un boxplot para poder visualizar las diferencias en la distribución de la economía del combustible según el sistema de tracción:



En cuanto a la variabilidad de los datos se destaca que los vehículos con tracción delantera (2- Wheel Drive, Front) presentan la mediana de MPG mas elevada, mientras que los vehículos con tracción 4- Wheel Drive presentan dispersión considerablemente menor.
Finalmente se identifican observaciones atípicas en casi todas las categorías, lo que sugiere la presencia de modelos con tecnologías de eficiencia diferenciada dentro de dicha categoría.

Evaluación de los supuestos y selección de la prueba

Se utilizó la prueba de Shapiro-Wilk para evaluar la normalidad de los datos en cada sistema de tracción. Los resultados mostraron p-valores inferiores en los cinco grupos, por lo que se rechazó el supuesto de normalidad.

En consecuencia, se seleccionó la prueba de Kruskal-Wallis, que se adecua para comparar tres o más grupos independientes.

Resultados de Kruskal-Wallis

- Estadístico: 422.18
- P-valor: 4.46×10^{-90}

Conclusión:

El p-valor obtenido es considerablemente inferior al nivel de significancia establecido, por lo que se rechaza la hipótesis nula. Esto indica que existen diferencias estadísticamente significativas en la distribución de la economía de combustible entre los distintos sistemas de tracción. Se respalda la hipótesis planteada.

c) *"Entre vehículos a combustión, las características técnicas del vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana."*

Para realizar el análisis multivariado que se nos presenta en la hipótesis consideramos las siguientes variables, H0 y H1:

- **Variable dependiente:** Economía del combustible.
- **Variables independientes:**
  - De tipo cuantitativa continua: Peso, Potencia y Cilindrada.
  - De tipo cuantitativa discreta: Número de cilindros.
  - De tipo cualitativas: transmisión, sistema de tracción.
- **H0:** no existe una asociación significativa conjunta entre las características técnicas del vehículo (peso, potencia, cilindrada, cilindros, transmisión y tracción) y su eficiencia de combustible urbana en vehículos a combustión.

- **H1:** existe una asociación significativa conjunta entre al menos una de las características técnicas del vehículo (peso, potencia, cilindrada, cilindros, transmisión o tracción) y su eficiencia de combustible urbana en vehículos a combustión.

Estrategia de análisis:

Para evaluar la asociación conjunta planteada en la hipótesis implementamos un modelo de regresión lineal múltiple. Delimitamos los datos sobre la subpoblación de vehículos a combustión evaluados en la categoría FTP (prueba de manejo urbano) y eliminamos los registros con valores nulos, obteniendo un total de 1536 observaciones completas.

Para incorporar las variables cualitativas al modelo numérico, aplicamos One-Hot Encoding y finalmente la significancia global del modelo la evaluamos mediante la prueba F, analizando la significancia individual y el coeficiente de determinación.

Análisis de resultados:

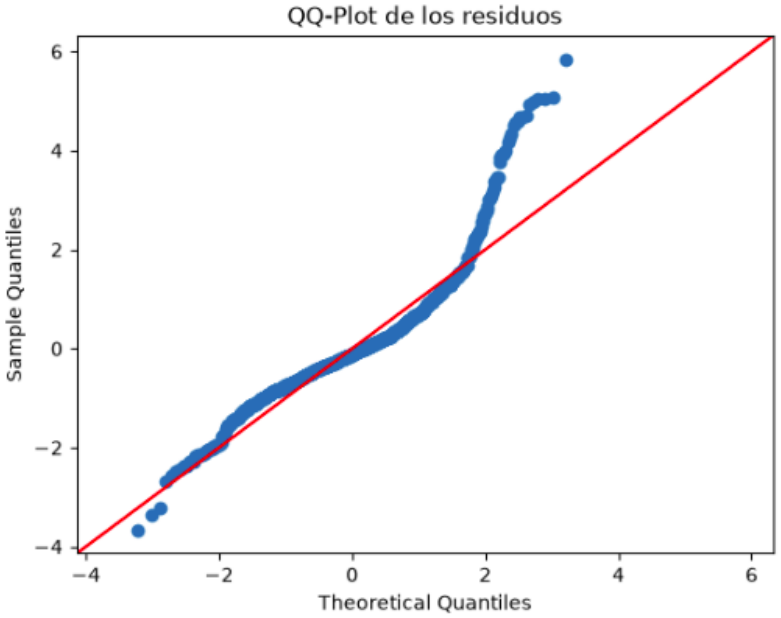
El modelo obtuvo un R^2 de 0,692 y un R^2 ajustado de 0,689, explicando aproximadamente el 69,2 de la variabilidad de la eficiencia de combustible, mientras que la prueba global presentó un estadístico F de 244,1 y un p-valor < 0.001.

Al ser este último inferior a 0,05, se rechaza la hipótesis nula y se encuentra evidencia de una asociación conjunta entre las características técnicas y la eficiencia de combustible.

En cuanto a los coeficientes, el peso, la potencia y la cilindrada presentaron asociaciones negativas significativas, mientras que la cantidad de cilindros presentó una asociación positiva. También se encontraron diferencias significativas en determinadas categorías de transmisión y tracción respecto de sus categorías de referencia.

Diagnóstico de residuos:
Se realizaron dos gráficos para evaluar los supuestos del modelo.

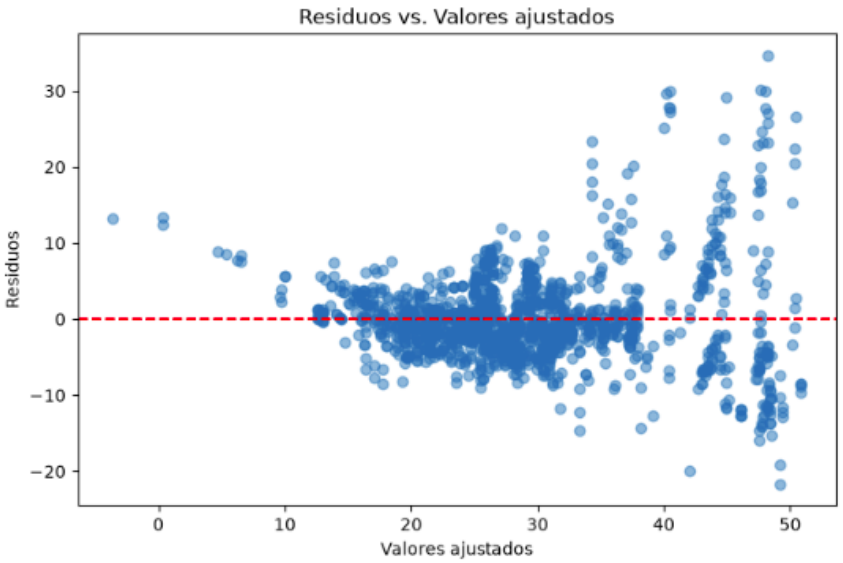
- QQ-Plot:



En esta evaluación gráfica del supuesto de normalidad podemos observar que la región central de la distribución se ajusta de forma coherente a la línea de normalidad. Aun así, en la cola superior se evidencia una desviación significativa, reflejando asimetría positiva y presencia de residuos altos.

Si bien no se está respetando la normalidad estricta en los errores, las inferencias y pruebas de significancia conservan su validez.

- Residuos y valores ajustados:



En este gráfico se analizan linealidad, homocedasticidad y presencia de outliers. La dispersión de los residuos aumenta para los valores ajustados más altos, formando un patrón similar a un abanico. Esto indica que la varianza de los errores no es constante, por

lo que existe heterocedasticidad. Mientras que para los valores bajos y medios (15 a 30) los errores se mantienen concentrados cerca de cero. Esto indica que la variabilidad de los errores no es constante a lo largo del rango de predicción, perdiendo precisión descriptiva en los vehículos con mayor eficiencia urbana.

Conclusión:
Encontramos evidencia de que las características técnicas de los vehículos están relacionadas conjuntamente con su eficiencia de combustible.

La regresión permitió explicar aproximadamente el 69,2 % de las diferencias en la eficiencia de combustible entre los vehículos. Además, el resultado de la prueba estadística fue significativo, lo que indica que esta relación difícilmente se deba al azar.

Al analizar cada característica por separado, observamos que el peso, la potencia y la cilindrada se relacionan con una menor eficiencia de combustible. En cambio, la cantidad de cilindros presentó una relación positiva. También encontramos diferencias según determinados tipos de transmisión y sistemas de tracción.

Por último, los gráficos de diagnóstico mostraron algunas limitaciones en el modelo, ya que los errores no se comportan completamente como esperamos. Por eso, debemos interpretar los resultados con cierta precaución.

Conclusión General

A lo largo de este trabajo realizamos un análisis exploratorio y estadístico del conjunto de datos de vehículos correspondientes al año modelo 2025. Comenzamos explorando las variables disponibles y realizando un proceso de limpieza para identificar y tratar valores nulos, inconsistencias y datos atípicos que pudieran afectar los resultados.

Posteriormente, analizamos las características de los vehículos mediante gráficos y medidas estadísticas, estudiando sus distribuciones y las relaciones entre distintas variables. También aplicamos técnicas de análisis univariado, bivariado y multivariado para investigar las hipótesis planteadas.

Los resultados obtenidos permiten observar que la eficiencia de combustible no depende de una única característica del vehículo, sino de la combinación de varios factores técnicos. El peso, la potencia y la cilindrada mostraron una relación negativa con el rendimiento: en general, los vehículos con valores más elevados en estas características tendieron a presentar menos MPG. Sin embargo, la cantidad de cilindros mostró un comportamiento diferente al esperado inicialmente, lo que demuestra que estas relaciones no siempre son iguales para todas las características. También encontramos diferencias de eficiencia entre los sistemas de tracción y observamos que no todas las configuraciones de vehículos a combustión alcanzan el umbral de 25 MPG en las pruebas urbanas.

En conjunto, estos resultados muestran que comparar vehículos únicamente por una característica puede llevar a conclusiones incompletas. Es necesario considerar sus

características técnicas de manera conjunta y tener en cuenta que distintas combinaciones de motor, peso, transmisión y tracción pueden dar lugar a diferentes niveles de eficiencia.

Finalmente, el trabajo nos permitió no solo identificar relaciones y patrones dentro del conjunto de datos, sino también reconocer las limitaciones de los análisis realizados. De esta manera, pudimos comprobar la importancia de una correcta limpieza de los datos y de combinar distintas herramientas estadísticas para obtener interpretaciones más completas y fundamentadas.